

Rapport de recherches IA



wildlife

Informations générales de ce document

Version	1.1.0
Date de la version	07/04/2023
Modifié par	Alexandre Saint-Albin
Date de création	16/02/2023
Crée par	Alexandre Saint-Albin

Historique de modification

Version	Date	Auteur	Commentaire
1.0.0	16/02/2023	Alexandre Saint-Albin	Création document
1.1.0	07/04/2023	Alexandre Saint-Albin	Ajout des résultats de l'IA

Développement d'une IA pour la classification d'espèces animales dans le cadre du projet Wildlife

Introduction.....	4
Choix et utilisation du dataset.....	5
Algorithmes de deep learning.....	7
Résultats.....	8
Conclusion.....	10
Sources.....	11

Introduction

Le projet Wildlife vise à développer une plateforme d'observation de la faune où les utilisateurs peuvent partager des photos et des vidéos d'animaux sauvages. Les informations générées par ces publications, telles que les coordonnées GPS, la date et l'espèce, seront mises à profit par des professionnels du secteur de la faune, comme les zoologistes et les biologistes. L'intelligence artificielle occupe une place centrale dans ce projet, notamment pour la reconnaissance automatique des espèces animales à partir des images fournies par les utilisateurs et les caméras connectées.

La classification d'espèces animales à partir d'images représente un défi complexe, qui nécessite des algorithmes de traitement d'images et d'apprentissage automatique performants. Les réseaux de neurones convolutifs (CNN) ont démontré leur efficacité dans ce domaine, en particulier pour les tâches de classification d'images. Le transfert learning, une technique d'apprentissage, est couramment utilisé pour adapter un modèle pré-entraîné à de nouvelles données, facilitant ainsi la création d'un modèle de reconnaissance d'espèces animales pour le projet Wildlife.

Dans ce rapport de recherche, nous présentons le développement d'une IA destinée à la classification d'espèces animales dans le cadre du projet Wildlife, en explorant différentes architectures de CNN et en utilisant le transfert learning pour optimiser les performances de notre modèle.

Choix et utilisation du dataset

Le choix du dataset est crucial pour le succès de tout projet d'apprentissage automatique. Dans notre projet Wildlife, nous avons utilisé le dataset d'iNaturalist 2021, qui est une collection d'observations d'espèces animales et végétales. iNaturalist est une communauté en ligne et une application web qui permet aux utilisateurs de documenter et de partager leurs observations de la nature, contribuant ainsi à un vaste ensemble de données pour la recherche en biodiversité.

Nous avons choisi d'utiliser le dataset d'iNaturalist pour plusieurs raisons :

- Richesse et diversité des données : iNaturalist contient des millions d'observations d'espèces animales et végétales du monde entier, offrant ainsi un ensemble de données riche et diversifié pour entraîner notre modèle de classification.
- Annotations précises : Les observations d'iNaturalist sont annotées par des experts et des passionnés de la nature, ce qui garantit une grande qualité et une précision des étiquettes d'espèces.
- Cohérence avec le projet Wildlife : iNaturalist partage des objectifs similaires avec notre projet, en encourageant les utilisateurs à observer et à documenter la faune. L'utilisation du dataset d'iNaturalist est donc cohérente avec l'orientation et les besoins de notre projet.

Il existe d'autres datasets qui pourraient être utilisés pour entraîner un modèle de classification d'espèces animales, tels qu'ImageNet, qui est un vaste ensemble de données contenant des millions d'images réparties en milliers de catégories, dont un grand nombre d'espèces animales. Un autre exemple est le dataset CIFAR, qui comprend 60 000 images de 10 classes différentes, dont certaines représentent des animaux tels que les oiseaux, les chats, les cerfs et les chiens. Cependant, ces datasets présentent certaines limitations pour notre projet Wildlife.

ImageNet, bien qu'étant un ensemble de données riche et diversifié, couvre un large éventail de catégories allant bien au-delà des espèces animales. La sélection et l'extraction d'un sous-ensemble pertinent d'espèces animales à partir d'ImageNet pourrait s'avérer complexe et fastidieuse. De plus, ImageNet est un ensemble de données massif qui nécessite des ressources de calcul importantes pour l'entraînement.

Quant au dataset CIFAR, bien qu'il contienne des images d'animaux, il est limité en termes de diversité des espèces et ne couvre qu'un petit nombre d'animaux par rapport à iNaturalist. De plus, les images de CIFAR sont de faible résolution (32x32 pixels), ce qui pourrait compromettre la qualité et la précision de notre modèle de classification d'espèces animales.

En comparaison, le dataset d'iNaturalist offre une meilleure couverture des espèces animales et une qualité d'image supérieure. De plus, étant spécifiquement axé sur la biodiversité, il est mieux adapté à notre projet Wildlife.

Pour adapter le dataset d'iNaturalist à notre projet, nous avons décidé de nous concentrer sur 50 espèces d'animaux européens pertinentes pour notre étude. Cette sélection nous a permis de nous concentrer sur les espèces les plus représentatives et les plus pertinentes pour notre plateforme d'observation de la faune. De plus, cette réduction du nombre d'espèces a été réalisée pour des raisons de limitations de ressources de calcul et de temps. Entraîner un modèle sur un dataset plus volumineux et diversifié nécessite une puissance de calcul importante et un temps de traitement plus long. En nous concentrant sur un nombre réduit d'espèces, nous avons pu réduire les exigences en matière de calcul et de temps, tout en nous assurant d'obtenir un modèle suffisamment précis pour les espèces sélectionnées.

Algorithmes de deep learning

Pour développer notre modèle de classification d'espèces animales, nous avons utilisé la méthode de transfert learning avec trois architectures de réseaux de neurones convolutifs (CNN) populaires et performantes : **VGG16**, **ResNet50** et **InceptionV3**. Voici une présentation détaillée de chaque algorithme, ainsi que des comparaisons et justifications de leur utilisation dans notre projet.


- VGG16: Le modèle VGG16, développé par l'équipe de recherche Visual Geometry Group de l'Université d'Oxford, est une architecture de CNN composée de 16 couches pondérées. Il a été initialement développé pour le défi de classification d'images ImageNet en 2014 et a obtenu d'excellents résultats. VGG16 est apprécié pour sa simplicité et sa facilité d'implémentation. Cependant, sa profondeur et le grand nombre de paramètres entraînent une consommation importante de ressources et de temps de calcul. Dans notre projet, nous avons exploré l'utilisation de VGG16 pour la classification d'espèces animales, car il a été largement utilisé et cité dans des travaux antérieurs dans le domaine de la classification d'images.
- ResNet50: Le modèle ResNet50 est un réseau de neurones convolutif avec 50 couches pondérées, développé par Microsoft Research. Il est basé sur l'architecture ResNet (Residual Network) qui introduit des connexions résiduelles, permettant de résoudre le problème de la disparition du gradient dans les réseaux profonds. ResNet a remporté le défi ImageNet en 2015 en établissant un nouveau record en matière de précision. La principale force de ResNet réside dans sa capacité à apprendre des caractéristiques complexes tout en réduisant les problèmes de convergence liés aux réseaux profonds. Dans notre projet, nous avons utilisé ResNet50 en raison de sa performance éprouvée et de sa capacité à gérer efficacement les réseaux profonds pour la classification d'images.
- InceptionV3: InceptionV3 est une architecture de CNN développée par Google et constitue la troisième version de la famille Inception. Il utilise des modules Inception, qui permettent d'apprendre des caractéristiques à différentes échelles spatiales et de réduire le nombre de paramètres sans sacrifier la performance. InceptionV3 a obtenu de très bons résultats dans diverses compétitions de classification d'images, notamment ImageNet. L'architecture Inception est particulièrement adaptée à notre projet en raison de sa capacité à traiter des images de haute résolution et de sa performance élevée avec un nombre de paramètres relativement faible.

Dans notre étude, nous avons choisi d'explorer ces trois algorithmes car ils ont fait leurs preuves dans des travaux antérieurs et des compétitions de classification d'images. De plus, leur utilisation dans d'autres projets de classification d'espèces animales nous a fourni des points de référence pour évaluer leur performance dans le contexte du projet Wildlife.


Résultats

Après avoir entraîné et comparé les performances de ces trois architectures, nous avons obtenu les résultats suivant :


InceptionV3: 63% en validation et 82% en test



VGG16: 36% en validation et 50% en test



Et Resnet50 avec 12% en validation et 4% en test



(voir les notebooks pour les résultats complets)

Cette performance supérieure est due à la capacité d'InceptionV3 à gérer efficacement des images de haute résolution et à apprendre des caractéristiques complexes avec un nombre de paramètres relativement faible, ce qui le rend particulièrement adapté à la classification d'espèces animales dans notre projet.

Conclusion

Au cours de ce projet, nous avons exploré et mis en œuvre des techniques d'IA pour la classification d'espèces animales. Les défis rencontrés comprenaient le choix d'un modèle adapté pour la classification d'images, la sélection d'un dataset pertinent et représentatif, ainsi que la gestion des contraintes de temps et de ressources de calcul.

Nous avons utilisé le transfert learning pour entraîner trois modèles de deep learning populaires - VGG16, ResNet50 et InceptionV3 - et avons obtenu les meilleurs résultats avec l'architecture InceptionV3. Bien que notre modèle actuel présente une certaine précision, il existe plusieurs axes d'amélioration pour optimiser davantage les performances et étendre les capacités de notre système de classification d'espèces animales.

Voici des axes d'améliorations de l'IA pour le projet :

Entraînement sur un plus grand nombre d'espèces : Actuellement, notre modèle est entraîné sur un sous-ensemble de 50 espèces d'animaux européens en raison des contraintes de temps et de ressources de calcul. En augmentant progressivement le nombre d'espèces animales prises en compte, nous pourrions améliorer la généralisation de notre modèle et le rendre plus utile pour un plus grand nombre d'utilisateurs.

Enrichissement du dataset : L'ajout de données supplémentaires, telles que des images prises dans des conditions d'éclairage, de météo ou de saison différentes, pourrait améliorer la robustesse et la précision du modèle en lui permettant de mieux comprendre la variabilité des caractéristiques visuelles des animaux.

Exploration de techniques d'augmentation de données : L'utilisation de techniques d'augmentation de données, telles que la rotation, la mise à l'échelle, le recadrage ou le retournement d'images, peut aider à enrichir le dataset et à augmenter la capacité du modèle à généraliser à partir de données d'entrée variées.

Optimisation des hyperparamètres : En expérimentant et en ajustant les hyperparamètres du modèle, tels que le taux d'apprentissage, la taille du lot ou le nombre d'époques d'entraînement, nous pourrions potentiellement améliorer les performances du modèle.

Comparaison avec d'autres architectures de deep learning : L'exploration d'autres architectures de réseaux de neurones convolutifs, ainsi que la mise en œuvre d'approches plus récentes et plus avancées en matière de classification d'images, pourrait nous permettre de trouver des modèles encore plus performants.

En résumé, notre projet Wildlife a permis de mettre en place un modèle de classification d'espèces animales basé sur l'architecture InceptionV3, offrant une base solide pour des améliorations et des extensions futures. En tenant compte des axes d'amélioration mentionnés ci-dessus, nous pourrions continuer à affiner et à optimiser notre modèle, contribuant ainsi à une meilleure compréhension et à une meilleure préservation de la biodiversité.

Sources

iNaturalist: https://github.com/visipedia/inat_comp/tree/master/2021

CIFAR: <https://www.cs.toronto.edu/~kriz/cifar.html>

ImageNet : <https://www.image-net.org/>

Utilisations IncetionV3:

- <https://hal.science/hal-03874232/document>
- <https://www.kaggle.com/c/dog-breed-identification>
- <https://towardsdatascience.com/car-classification-using-inception-v3-71b63e9825b7>

ResNet50:

- <https://medium.com/@nina95dan/simple-image-classification-with-resnet-50-334366e7311a>
- <https://www.kaggle.com/code/dskagglemt/car-image-classification-using-resnet50>

VGG16:

- <https://www.learndatasci.com/tutorials/hands-on-transfer-learning-keras/>
- <https://towardsdatascience.com/how-to-use-a-pre-trained-model-vgg-for-image-classification-8dd7c4a4a517>